

RAG Чат-бот по роману «Мастер и Маргарита»

Курс «Введение в LLM»

Команда bookworm

ИТМО

Январь 2026

Горбунов Дмитрий, Ковалева Дарина, Тельнов Федор, Мацаков Борис

Проблема и цели проекта

Проблема:

- «Мастер и Маргарита» - много персонажей и сюжетных линий
- Поиск информации требует перечитывания книги
- LLM без RAG галлюцинирует и путает детали сюжета

Цель: Создать чат-бота, который отвечает на вопросы **только на основе текста книги**

Задачи:

1. Подготовить текст для RAG-поиска
2. Реализовать retrieval-пайплайн
3. Создать удобный веб-интерфейс
4. Оценить качество ответов

Сбор и подготовка данных

Источник:

- Флибуста (FB2 формат)
- 580 000 символов
- 32 главы + эпилог

Подготовка:

1. Парсинг FB2 (XML)
2. Разбиение на главы
3. Chunking: 800 симв., overlap 100
4. Эмбединги: GigaChat (1024 dim)
5. Индексация: FAISS


Итог:

Метрика	Значение
Чанков	1 182
Размерность	1024
Индекс	FAISS FlatIP

Хранение:

- chunks.parquet
- embeddings.parquet
- faiss_index/

Архитектура решения



Компоненты системы

Data Service:

- Парсинг FB2
- RecursiveCharacterTextSplitter
- Метаданные глав

RAG Service:

- GigaChat Embeddings
- FAISS IndexFlatIP
- BGE-reranker-base (опц.)

LLM Service:

- OpenRouter (GPT-4o-mini)
- Claude Haiku (альт.)
- Строгий промпт: только контекст

Frontend:

- Streamlit
- История чата
- Показ источников
- Переключатель реранкера

Оценка качества

Инструмент: RAGAS (Retrieval Augmented Generation Assessment)

Валидационная выборка: 70 вопросов с эталонными ответами

Метрика	Что измеряет
Faithfulness	Нет галлюцинаций в ответе
Answer Relevancy	Релевантность ответа вопросу
Context Precision	Точность найденных фрагментов
Context Recall	Полнота покрытия эталонного ответа

Эксперименты и результаты

Финальные метрики (70 вопросов):

Метрика	Без реранк.	С реранк.
Faithfulness	0.856	0.821
Answer Relevancy	0.358	0.398
Context Precision	0.487	0.474
Context Recall	0.431	0.421

Выводы:

- Реранкер: +0.040 к relevancy
- GigaChat эмбединги уже хорошо ранжируют
- Faithfulness 0.856 - мало галлюцинаций

Что не работало:

- OpenAI Embeddings - VPN
- GigaChat LLM - rate limits


Итоговый продукт

Возможности:

- Ответы на вопросы по книге
- Показ источников и цитат
- Переключение реранкера
- История диалога

Запуск:

- `pip install -r requirements.txt`
- `streamlit run frontend/app.py`
- Или: `docker-compose up`



Команда и распределение ролей

Участник	Вклад
Горбунов Дмитрий	MVP: chunking, embeddings, RAG-пайплайн, UI
Ковалева Дарина	Реранкер (BGE), сравнительный анализ
Тельнов Федор	Проектирование архитектуры, диаграммы
Мацаков Борис	Модуль оценки (RAGAS), валидация качества

Репозиторий: <https://github.com/bookworm-itmo/llm-intro-project>

Вопросы?

GitHub: <https://github.com/bookworm-itmo/llm-intro-project>

Telegram: @grbn_dima